Agrupar flores sin usar sus especies: clustering, PCA y SVD en Iris

Karen Sofía Delgado Calderon

Universidad de Cundinamarca

Especialización en Inteligencia Artificial

604012 – Introducción a Machine Learning

28 de octubre de 2026

Agrupar flores sin usar sus especies: clustering, PCA y SVD en Iris

Una agrupación útil debe acercar observaciones semejantes sin recibir de antemano su categoría. La guía de clustering del curso propone Iris para practicar K-means y una comparación con métodos jerárquicos (Universidad de Cundinamarca, s. f.). Aquí se retoma esa idea con una pregunta concreta: ¿las cuatro medidas de las flores permiten identificar tres grupos y cuánto se pierde al reducirlas a dos componentes? El cuaderno compatible con Google Colab, con salidas ejecutadas y guardadas, y los datos de las figuras están en https://github.com/sofiadelcal/karen-ml-no-supervisado-iris. No se usaron las especies para entrenar ni escoger los grupos; se reservaron para una evaluación externa.

Fundamentos y utilidad

El aprendizaje no supervisado busca estructura en las variables observadas sin ajustar una respuesta etiquetada. En este caso, agrupar significa construir conjuntos de flores semejantes; reducir dimensiones significa representar las mismas flores con menos coordenadas. Son tareas distintas: PCA no asigna especies y una etiqueta de cluster no es una identificación botánica. K-means alterna la asignación al centroide más cercano y la actualización de centroides para reducir $J = \sum_{j=1}^{k} \sum_{x_i \in C_j} \|x_i - \mu_j\|_2^2$. Favorece grupos compactos y depende de la escala, la inicialización y k. Ward parte de observaciones individuales y fusiona grupos según el incremento de variación interna; el dendrograma conserva la secuencia de fusiones. DBSCAN exige densidad local y permite puntos sin asignar, pero depende de su radio y del mínimo de vecinos (Scikit-learn developers, s. f.-a).

Una aplicación de esta comparación sería organizar mediciones de un vivero para revisar lotes parecidos y localizar observaciones atípicas. DBSCAN podría señalar flores que requieren inspección, aunque una marca de ruido no demuestra un error ni una enfermedad. La utilidad depende de contrastar los grupos con conocimiento botánico; este conjunto didáctico no valida ese uso operativo.

Método

Se cargaron las 150 flores y cuatro medidas del conjunto `load_iris` (Scikit-learn developers, s. f.-b). No hay valores faltantes. Las variables se estandarizaron a media cero y desviación estándar uno antes de calcular distancias, pues longitud y anchura no deben pesar de modo diferente solo por su escala. Se compararon K-means para $k = 2, \ldots, 6$, con 20 inicializaciones y semilla 42, mediante inercia y silueta. La inercia solo es comparable entre modelos K-means sobre los mismos datos y decrece al crecer k; por eso también se examinó la separación medida por silueta. Se conservó $k = 3$ para contrastar el ejercicio de la guía, aunque la mejor silueta resultó en otro valor. Con tres grupos se ajustaron K-means y agrupamiento aglomerativo de Ward. También se exploró DBSCAN con $\varepsilon = 0{,}7$ y mínimo de cinco vecinos, para mostrar qué ocurre al exigir densidad local. Se calcularon silueta, índice de Davies–Bouldin (menor es mejor) e índice de Rand ajustado (ARI) frente a la especie. Este último no dirige ningún ajuste: solo comprueba, una vez obtenidos los grupos, cuánto coinciden con una clasificación conocida. En DBSCAN la silueta y Davies–Bouldin se calcularon excluyendo las muestras declaradas ruido; el ARI sí incluye su etiqueta -1. Por ello la comparación de su silueta con métodos que asignan las 150 flores debe leerse con cautela (Scikit-learn developers, s. f.-a).

Para visualizar se aplicó PCA a la matriz estandarizada. Después se realizó explícitamente una descomposición en valores singulares (SVD) de la misma matriz centrada y se reconstruyó con rango dos. PCA usa SVD para hallar los ejes de máxima varianza; sobre la misma matriz, ambas reconstrucciones deben coincidir salvo errores numéricos (Scikit-learn developers, s. f.-c). Se midió la varianza retenida y el error relativo $\|X - X_2\|_F / \|X - \bar{X}\|_F$.

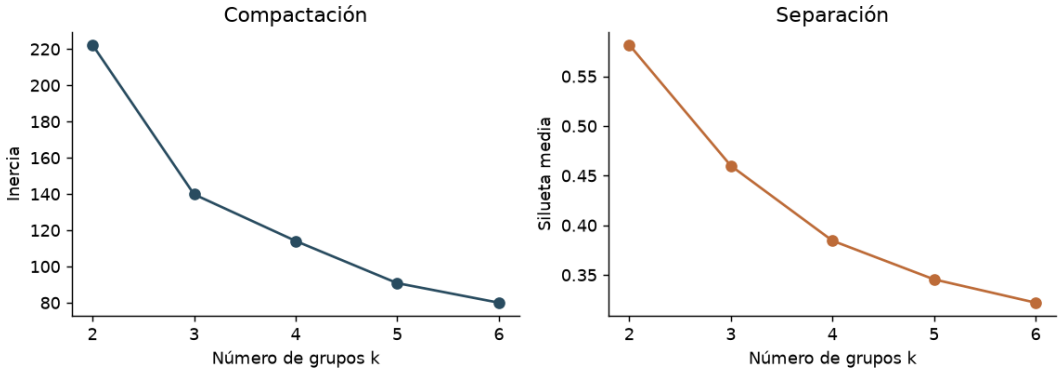
Resultados del agrupamiento

La Figura 1 muestra que la silueta alcanza 0,5818 con dos grupos; con tres baja a 0,4599. Por tanto, no se presenta $k = 3$ como un óptimo impuesto por los datos: es una elección didáctica para estudiar tres grupos comparables con la guía. La inercia cae de forma continua y no ofrece por sí

sola un corte inequívoco.

Figura 1

Compactación y separación entre dos y seis grupos



Nota. Se usaron las cuatro variables estandarizadas, 20 inicializaciones y semilla 42. La inercia no se comparó con otros algoritmos. Elaboración propia a partir del cuaderno.

Tabla 1

Comparación de tres métodos sobre las medidas estandarizadas

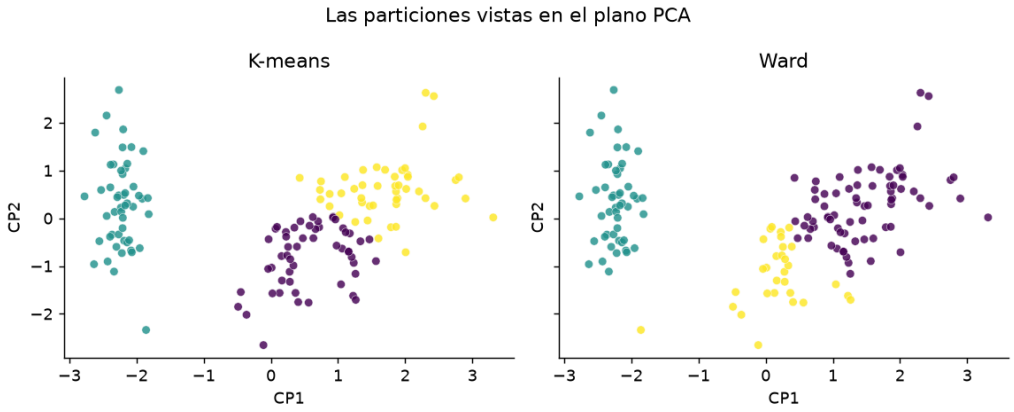
Método	Grupos	Ruido	Silueta	ARI externo
K-means ($k = 3$)	3	0	0,4599	0,6201
Ward ($k = 3$)	3	0	0,4467	0,6153
DBSCAN	2	6	0,6018	0,5401

Nota. En DBSCAN la silueta excluye las seis flores marcadas como ruido; el ARI las incluye. Davies–Bouldin fue 0,8336, 0,8035 y 0,5568, respectivamente. Datos de `resultados/comparacion_metodos.csv`; elaboración propia.

La Tabla 1 permite comparar los métodos. El ARI de K-means (0,6201) y Ward (0,6153) indica coincidencia parcial con las especies, no una recuperación perfecta. DBSCAN encontró dos grupos y aisló seis flores; su silueta de 0,6018 se calcula sobre un subconjunto y responde a otra pregunta. Así, una cifra de silueta más alta no implica automáticamente mejor correspondencia con las tres especies. La Figura 2 sitúa ambas particiones de tres grupos en los mismos ejes; la Figura 3 presenta la parte final de la jerarquía.

Figura 2

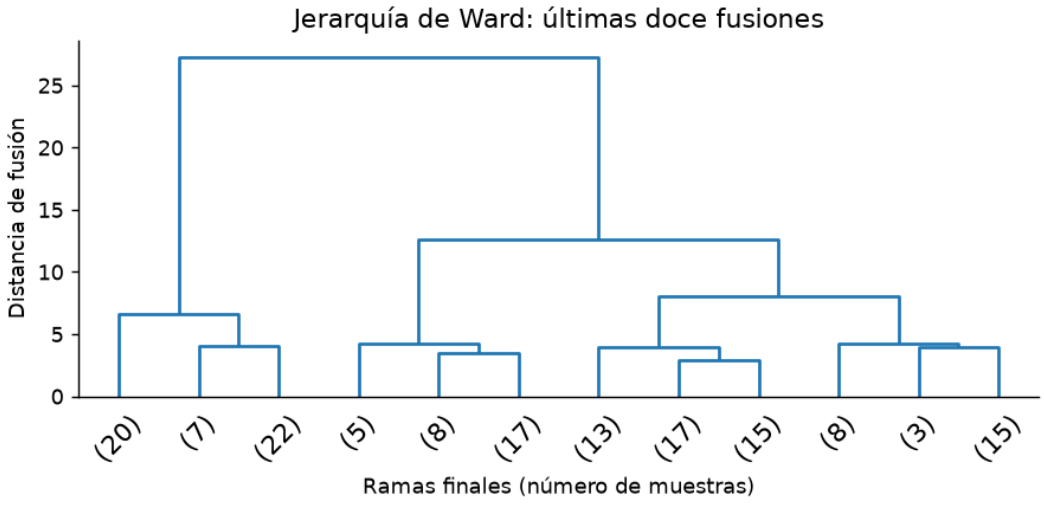
K-means y Ward proyectados sobre las dos primeras componentes



Nota. Los colores son etiquetas de grupo, no especies. La agrupación se hizo en cuatro dimensiones y se proyectó después; una separación aparente en el plano no sustituye las métricas originales. Elaboración propia.

Figura 3

Últimas fusiones del agrupamiento de Ward



Nota. Dendrograma truncado a 12 hojas; una hoja puede representar varias flores. La altura expresa distancia de fusión, no probabilidad. Elaboración propia con las cuatro variables estandarizadas.

La jerarquía permite escoger diferentes cortes sobre las mismas fusiones. Una unión alta implica mayor diferencia entre los grupos que se fusionan. Sin embargo, el gráfico truncado no permite inspeccionar cada flor. K-means formó grupos de 53, 50 y 47 observaciones y su acuerdo con Ward fue ARI = 0,6255: producir tres grupos de tamaños semejantes no implica asignar las

mismas flores. Además, Ward obtuvo menor Davies–Bouldin (0,8035 frente a 0,8336), mientras K-means tuvo mayor silueta; ninguna partición domina todos los criterios.

Qué conserva la reducción

Las dos primeras componentes de PCA retuvieron el 95,81 % de la varianza estandarizada. La reconstrucción SVD de rango dos produjo un error relativo de 0,2046. La diferencia máxima entre las reconstrucciones de PCA y SVD fue $1,67 \times 10^{-15}$, compatible con redondeo numérico. Esta concordancia comprueba la implementación algebraica, pero no significa que todas las flores puedan distinguirse sin pérdida en dos dimensiones. El porcentaje de varianza tampoco mide por sí mismo la calidad de los grupos.

Para la matriz centrada $X_c = U\Sigma V^{\mathsf{T}}$, la aproximación usada es $X_2 = U_2\Sigma_2 V_2^{\mathsf{T}}$. El error relativo al cuadrado equivale a la fracción de energía descartada: $0{,}2046^2 \approx 0{,}0419$. Así se reconcilian dos cifras que podrían parecer contradictorias: un error de norma del 20,46 % y una varianza descartada del 4,19 % expresan magnitudes diferentes. El cálculo utiliza datos centrados y estandarizados; no debe trasladarse sin cambios a una SVD de datos sin centrar.

Conclusiones

La decisión más delicada fue el número de grupos. Dos favoreció la silueta, mientras tres permitió estudiar la estructura que plantea la guía. Ninguna medida determina automáticamente el objetivo de análisis: si el propósito es separar especies, el ARI externo revela errores que la silueta interna no detecta. K-means y Ward dieron resultados semejantes con $k = 3$, aunque sus reglas de construcción son diferentes. DBSCAN enseñó otra consecuencia de cambiar el supuesto geométrico: agrupar por densidad dejó seis puntos sin asignar y encontró solo dos regiones.

PCA facilitó una visualización legible y SVD permitió cuantificar su costo: casi toda la variación quedó en dos componentes, pero el error de reconstrucción no fue cero. El trabajo se limita a 150 observaciones conocidas y a una escala fijada. Antes de usar los grupos para clasificar flores nuevas sería necesario evaluar estabilidad ante nuevas muestras, otras estandarizaciones y

distintas semillas. El notebook conserva código, salidas y archivos de resultados para repetir cada cifra; el informe no atribuye valor predictivo a una agrupación calculada solo sobre este conjunto.

Reproducción y evidencia de ejecución

El cuaderno se ejecutó de principio a fin en Google Colab el 27 de octubre de 2026, sin errores. Puede abrirse mediante el enlace siguiente y elegir *Entorno de ejecución* >*Ejecutar todo*. Los datos están incluidos en scikit-learn: no se requiere cargar archivos, conectar Drive ni proporcionar credenciales. Las celdas siguen el orden carga, estandarización, comparación de k, ajuste de modelos, evaluación, reducción y exportación.

Abrir el cuaderno de Karen en Google Colab.

El repositorio enlazado en la introducción contiene el notebook con salidas visibles, instrucciones de ejecución en el README, dependencias y la carpeta `resultados/`. Allí, `seleccion_k.csv` respalda la elección de grupos, `comparacion_metodos.csv` respalda la tabla de evaluación y `resumen.json` conserva las medidas de reducción. Las figuras PNG se regeneran desde las mismas celdas. Las diferencias próximas a 10^{-15} entre ejecuciones de PCA y SVD corresponden al redondeo de punto flotante; no alteran las conclusiones ni deben interpretarse como cambios sustantivos.

Referencias

Scikit-learn developers. (s. f.-a). *Clustering*. scikit-learn. https://scikit-learn.org/stable/modules/clustering.html

Scikit-learn developers. (s. f.-b). *load_iris*. scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_iris.html

Scikit-learn developers. (s. f.-c). *PCA*. scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html

Universidad de Cundinamarca. (s. f.). *Guía implementación de Clustering* [Material del curso]. https://posgrado.ucundinamarca.edu.co/mod/resource/view.php?id=73634